

Otimização Multiobjetivo de Hiperparâmetros via MOPSO-CD: Classificação da Doença de Parkinson Baseada em Atributos Vocais

Anderson Coelho Viana, PPGEE, UFPA Alfa Marine Damasceno Ferreira, PPGEE, UFPA,

Resumo—Este trabalho investiga a otimização multiobjetivo de hiperparâmetros de um classificador baseado em Máquinas de Vetores de Suporte com *kernel* Gaussiano (SVC-RBF), aplicado à classificação da Doença de Parkinson a partir de atributos vocais. Considerando dados reais, desbalanceados e estruturados por sujeito, o problema é formulado como um problema multiobjetivo, visando simultaneamente maximizar a acurácia balanceada média e minimizar a variabilidade do desempenho em validação cruzada por grupos. A estratégia de otimização empregada utiliza um método de Enxame de Partículas Multiobjetivo com critério de diversidade baseado em *Crowding Distance* (MOPSO-CD), implementado por meio da biblioteca *pymoo*. Os resultados experimentais demonstram melhorias consistentes em relação a uma linha de base sem otimização, além de fornecer um conjunto de soluções Pareto-ótimas que evidenciam o compromisso entre desempenho e estabilidade do modelo.

Index Terms—Doença de Parkinson, Otimização Multiobjetivo, MOPSO-CD, SVM, Atributos Vocais, Aprendizado de Máquina.

I. INTRODUÇÃO

A Doença de Parkinson (DP) é um distúrbio neurodegenerativo progressivo que afeta o sistema nervoso central, sendo caracterizado principalmente por alterações motoras, tais como tremor de repouso, rigidez muscular, bradicinesia e instabilidade postural. De acordo com a Organização Mundial da Saúde, a prevalência global da DP tem aumentado significativamente nas últimas décadas, configurando-se como um relevante problema de saúde pública [1].

Além das manifestações motoras clássicas, estudos recentes indicam que a DP também provoca alterações sutis e persistentes nos padrões vocais dos indivíduos, decorrentes do comprometimento do controle neuromuscular da fonação. Nesse contexto, atributos acústicos extraídos da voz têm sido amplamente investigados como biomarcadores não invasivos para o diagnóstico e monitoramento da doença [2]–[4]. Tais abordagens apresentam vantagens relevantes, incluindo baixo custo, facilidade de aquisição e potencial aplicação em cenários de telemonitoramento clínico.

Métodos computacionais baseados em processamento digital de sinais têm sido fundamentais para extrair atributos vocais como medidas de instabilidade de frequência (*jitter*),

amplitude (*shimmer*) e ruído, as quais servem de entrada para algoritmos de classificação supervisionada. Com o avanço das técnicas de aprendizado de máquina, diversos modelos de classificação têm sido empregados para a detecção automática da DP a partir de atributos vocais [5]. Dentre os modelos empregados para a classificação de sinais vocais, as Máquinas de Vetores de Suporte (*Support Vector Machine* - SVM), especificamente na configuração de *Support Vector Classifier* (SVC), ganharam destaque devido à sua capacidade de lidar com dados de alta dimensionalidade e fornecer margens de separação robustas em conjuntos de dados biomédicos de escala limitada [6], [7].

Todavia, o desempenho desses modelos é fortemente dependente da adequada configuração de seus hiperparâmetros, o que torna o processo de ajuste um desafio não trivial. Tradicionalmente, este ajuste é realizado via *Grid Search* ou *Random Search*, técnicas que, embora úteis, frequentemente negligenciam a natureza multiobjetivo do problema, focando apenas na maximização de métricas de desempenho médio, como a acurácia, e negligenciando a estabilidade do modelo frente à variabilidade intersujeito [8], [9].

O problema de seleção de hiperparâmetros é agravado em cenários reais, nos quais os dados frequentemente apresentam desbalanceamento entre classes, variabilidade intersujeitos e risco de *data leakage*. Além disso, o espaço de busca associado aos hiperparâmetros do SVC utilizando um *kernel Radial Basis Function* (RBF) é contínuo e de alta sensibilidade, o que remete ao fenômeno conhecido como *maldição da dimensionalidade*, dificultando a obtenção de soluções robustas por métodos de busca exaustiva ou heurísticas simples [10].

Para superar essas limitações, técnicas de otimização meta-heurísticas baseadas em inteligência de enxame têm sido exploradas para a sintonização fina de modelos de aprendizado de máquina [11]. O uso de algoritmos multiobjetivo representa uma evolução nesse campo, permitindo que o processo de busca considere não apenas o desempenho preditivo, mas também a estabilidade estatística do classificador.

Diante desse cenário, a otimização multiobjetivo surge como uma alternativa adequada para lidar simultaneamente com critérios de desempenho potencialmente conflitantes. Em particular, este trabalho propõe a formulação do problema de ajuste de hiperparâmetros do classificador SVC-RBF como um problema de otimização multiobjetivo, no qual busca-se maximizar a acurácia balanceada média e, simultaneamente, minimizar a instabilidade do modelo, medida pelo desvio padrão dessa métrica ao longo dos *folds* de validação cruzada.

A. C. Viana, discente do Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal do Pará - Brasil. e-mail: (andviana@gmail.com).

A. M. D. Ferreira, discente do Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal do Pará - Brasil. e-mail: (alfamarine.ferreira@gmail.com).

Manuscrito recebido em 30 de janeiro, 2026.

Para a resolução desse problema, emprega-se o algoritmo *Multi-Objective Particle Swarm Optimization* [12] com *Crowding Distance* (MOPSO-CD), conforme implementado na biblioteca *pymoo* [13]. A abordagem adotada permite a obtenção de um conjunto de soluções não-dominadas, organizadas em uma Fronteira de Pareto, fornecendo subsídios para a análise do compromisso entre desempenho médio e robustez do classificador, além de garantir a diversidade no conjunto de soluções, promovida pelo mecanismo de *crowding distance*.

Outro ponto contemplado na abordagem apresentada neste estudo foi a inserção do limiar de decisão (t) dentro dos objetivos da otimização e o tratamento do desbalanceamento dos dados clínicos através do uso da Técnica de Sobreamostragem de Minorias Sintéticas (SMOTE) [14]. Ressalta-se que a escolha de uma solução específica a partir da Fronteira de Pareto constitui uma etapa decisória posterior e não faz parte do processo de otimização propriamente dito.

II. MODELAGEM DO PROBLEMA

A modelagem adequada do problema de otimização constitui uma etapa fundamental para o sucesso da abordagem proposta, uma vez que define formalmente o espaço de busca, as variáveis de decisão, os objetivos e as restrições envolvidas. Neste trabalho, o ajuste dos hiperparâmetros do classificador SVC-RBF é formulado como um problema de otimização multiobjetivo contínuo.

A. Espaço de Decisão

Seja $\Omega \subset \mathbb{R}^3$ o espaço de decisão do problema, composto por três variáveis contínuas associadas aos principais hiperparâmetros do classificador SVC-RBF e ao limiar de decisão do modelo. O vetor de decisão é definido como:

$$\mathbf{x} = [x_1, x_2, x_3]^T, \quad (1)$$

onde:

- $x_1 = \log_{10}(C)$ representa o parâmetro de regularização do SVC, responsável pelo compromisso entre maximização da margem e penalização de erros de classificação;
- $x_2 = \log_{10}(\gamma)$ corresponde ao coeficiente do *kernel* RBF, controlando a influência de cada amostra no espaço de características;
- $x_3 = t$ denota o limiar de classificação aplicado à saída contínua do classificador, permitindo o ajuste do viés entre classes em cenários desbalanceados.

Para a avaliação de cada vetor de decisão $\mathbf{x}$, as variáveis x_1 e x_2 são mapeadas de volta para suas escalas originais através das transformações $C = 10^{x_1}$ e $\gamma = 10^{x_2}$. Essa estratégia permite que o algoritmo explore de forma uniforme ordens de magnitude que variam de 10^{-3} a 10^3 para a regularização, e de 10^{-6} a 10^1 para o parâmetro do *kernel*, garantindo uma cobertura abrangente do espaço de busca.

A adoção de escalas logarítmicas para os parâmetros C e γ é amplamente empregada na literatura, pois reduz a sensibilidade do espaço de busca e favorece a exploração eficiente de diferentes ordens de magnitude [10].

Adicionalmente, expandindo o espaço de busca para além dos parâmetros estruturais do classificador, este trabalho propõe o uso de x_3 como uma variável de decisão. Diferente da abordagem convencional, onde o limiar de decisão do SVC é fixado em um valor estático, a inclusão de x_3 como uma variável de decisão permite que o otimizador encontre o ponto de corte ideal para as probabilidades de classe. Essa estratégia é particularmente eficaz para mitigar o viés em direção à classe majoritária, permitindo que o modelo seja ajustado para maximizar a acurácia balanceada em cenários de dados clínicos desbalanceados.

B. Kernel de Base Radial

O classificador SVC utilizado neste estudo emprega o *kernel* de base radial (RBF), definido por:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad (2)$$

onde $\gamma > 0$ controla a largura do *kernel* e, consequentemente, a capacidade do modelo de capturar padrões não lineares nos dados. Valores elevados de γ tendem a produzir modelos mais complexos e suscetíveis ao sobreajuste, enquanto valores reduzidos resultam em modelos excessivamente suaves [5].

C. Funções Objetivo

O problema é formulado como uma otimização multiobjetivo com dois critérios potencialmente conflitantes, avaliados a partir de validação cruzada com agrupamento por sujeito (*GroupKFold*). As funções objetivo são definidas como:

- $f_1(\mathbf{x})$: minimização do erro de classificação, expressa como o negativo da acurácia balanceada média;
- $f_2(\mathbf{x})$: minimização da instabilidade do modelo, medida pelo desvio padrão da acurácia balanceada ao longo dos *folds*.

Formalmente, as funções objetivo são dadas por:

$$f_1(\mathbf{x}) = -\frac{1}{K} \sum_{k=1}^K \text{BA}_k(\mathbf{x}), \quad (3)$$

$$f_2(\mathbf{x}) = \sqrt{\frac{1}{K} \sum_{k=1}^K (\text{BA}_k(\mathbf{x}) - \overline{\text{BA}}(\mathbf{x}))^2}, \quad (4)$$

onde BA_k representa a acurácia balanceada no k -ésimo *fold* e K é o número total de partições da validação cruzada.

A avaliação das funções objetivo para cada vetor de decisão $\mathbf{x}$ segue um rigoroso *pipeline* de processamento para garantir a fidedignidade dos resultados e evitar o *data leakage*. Para cada *fold* da validação cruzada, o processo consiste em: (i) limpeza de valores extremos via *Quantile Clipper*; (ii) normalização robusta dos atributos através do *Robust Scaler*; (iii) aplicação da técnica SMOTE para o balanceamento sintético das classes de treinamento; e (iv) treinamento do classificador SVC com os parâmetros mapeados de $\mathbf{x}$.

Vale ressaltar que o SMOTE é aplicado exclusivamente aos dados de treinamento de cada partição, preservando a

integridade dos dados de teste para a avaliação final da acurácia balanceada. Este *pipeline* garante que a otimização multiobjetivo busque soluções que não apenas performem bem nos dados vistos, mas que apresentem capacidade de generalização e estabilidade estatística.

A escolha da acurácia balanceada como métrica principal é justificada pela presença de desbalanceamento entre classes, sendo essa métrica mais adequada do que a acurácia tradicional nesses cenários [15].

A inclusão de $f_2(\mathbf{x})$ como um objetivo de minimização é motivada pela necessidade de obter modelos que apresentem robustez estatística frente à variabilidade biológica dos dados. Em cenários clínicos, é comum que modelos alcancem alto desempenho médio, mas exibam alta variância entre diferentes grupos de pacientes, o que indica uma baixa capacidade de generalização ou sensibilidade excessiva a amostras específicas.

Dessa forma, a minimização do desvio padrão busca soluções localizadas em regiões do espaço de busca onde o desempenho do classificador é consistente em todas as partições da validação cruzada. Ao tratar o compromisso entre desempenho preditivo e estabilidade como um problema multiobjetivo, o processo de otimização prioriza modelos que sejam simultaneamente precisos e confiáveis para aplicação em diagnósticos reais.

D. Domínios e Restrições

Os limites inferior (LB) e superior (UB) das variáveis de decisão foram definidos com base em recomendações da literatura e em experimentos preliminares. A Tabela I apresenta os domínios adotados.

E. Formulação Multiobjetivo

Dessa forma, o problema de otimização pode ser formalmente expresso como:

$$\min_{\mathbf{x} \in \Omega} \mathbf{F}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \end{bmatrix}, \quad (5)$$

em que Ω representa o espaço viável definido pelos domínios das variáveis de decisão.

A resolução desse problema não resulta em uma única solução ótima, mas em um conjunto de soluções não-dominadas que compõem a Fronteira de Pareto. Cada ponto da fronteira representa um compromisso distinto entre desempenho médio e robustez do classificador, cabendo ao analista selecionar a solução mais adequada de acordo com critérios adicionais ou restrições de aplicação.

F. Classificação do Problema:

De acordo com a taxonomia da programação matemática e dos problemas de otimização, a formulação proposta pode ser classificada como um problema de otimização multiobjetivo, contínuo, não linear e não restrito. As variáveis de decisão são definidas em um domínio contínuo, não havendo restrições explícitas além dos limites do espaço de decisão, enquanto as funções objetivo são avaliadas por meio de um *pipeline* de

TABELA I
DOMÍNIOS DAS VARIÁVEIS DE DECISÃO DO PROBLEMA DE OTIMIZAÇÃO

Variável	Descrição	LB	UB
x_1	$\log_{10}(C)$	-3	3
x_2	$\log_{10}(\gamma)$	-6	1
x_3	Limiar t	0.10	0.90

aprendizado de máquina do tipo *black-box*, envolvendo pré-processamento dos dados, reamostragem, validação cruzada por grupos e treinamento do classificador, o que inviabiliza a obtenção de expressões analíticas ou gradientes explícitos. Ademais, a presença de objetivos conflitantes, a maximização da acurácia balanceada média e a minimização de sua variabilidade ao longo dos *folds* de validação cruzada, caracteriza o problema como inerentemente multiobjetivo. Devido à natureza não convexa e estocástica do espaço de busca, métodos determinísticos clássicos mostram-se inadequados, justificando a adoção de uma abordagem meta-heurística inspirada na natureza para a aproximação do conjunto de soluções Pareto-ótimas, conforme amplamente discutido na literatura clássica de otimização evolutiva multiobjetivo [12], [16], [17]

III. METODOLOGIA

Esta seção descreve detalhadamente o *pipeline* metodológico adotado neste estudo, abrangendo o tratamento dos dados, a seleção de atributos, a construção do *pipeline* de aprendizado de máquina e o procedimento de validação empregado para avaliação do classificador SVC-RBF otimizado. O fluxo macroscópico das etapas executadas, desde o processamento inicial até a geração do modelo final, está ilustrado na Fig. 1.

A. Base de Dados e Tratamento Inicial

O conjunto de dados utilizado é composto por 195 instâncias reais de sinais vocais, provenientes de 32 sujeitos distintos, coletados em condições clínicas controladas. Cada instância representa um conjunto de medidas acústicas extraídas da voz sustentada, associadas ao diagnóstico de Doença de Parkinson ou a indivíduos saudáveis.

Inicialmente, o *dataset* original continha aproximadamente 1000 amostras sintéticas geradas por técnicas de balanceamento. A exclusão das amostras sintéticas pré-existentis foi vital para garantir que a otimização multiobjetivo fosse guiada por padrões fisiológicos reais, preservando a fidelidade clínica dos dados e evitando que o algoritmo aprendesse vieses de técnicas de sobreamostragem aplicadas de forma desconhecida anteriormente, conforme recomendado em estudos recentes sobre aprendizado em saúde [18].

Além disso, foi mantida a variável *subject_id*, representando o identificador único de cada indivíduo, permitindo a aplicação de estratégias de validação que evitam *data leakage* entre amostras do mesmo sujeito [3].

B. Seleção e Engenharia de Atributos

A etapa de engenharia de atributos teve como objetivo reduzir a dimensionalidade do espaço de características, mitigando



Figura 1. Fluxograma metodológico geral do sistema proposto.

os efeitos da maldição da dimensionalidade e aumentando a robustez do classificador. A partir do conjunto completo de variáveis acústicas, foi realizada uma análise de importância de atributos baseada em consenso entre diferentes métodos de aprendizado.

Como resultado, foram selecionadas 11 variáveis consideradas mais relevantes para a discriminação entre indivíduos com Doença de Parkinson e controles saudáveis. As variáveis finais utilizadas neste estudo foram:

- PPE,
- spread1,
- spread2,
- D2,
- DFA,
- Fo (Hz),
- Fhi (Hz),
- Shimmer:DDA,
- MDVP:Shimmer(dB),
- MDVP:APQ,
- NHR.

As variáveis selecionadas englobam medidas fundamentais de frequência fundamental, medidas de perturbação de amplitude e frequência, além de indicadores de ruído e complexidade não linear (fractais). A adoção desse subconjunto reduzido visa equilibrar capacidade preditiva e complexidade do modelo, conforme evidenciado em estudos prévios sobre análise vocal na Doença de Parkinson [2], [4].

C. Seleção do Modelo Base por Benchmark Multicritério

Antes da etapa de otimização multiobjetivo dos hiperparâmetros, foi realizado um estudo comparativo entre diferentes modelos de classificação supervisionada, com o objetivo de selecionar o classificador base mais adequado ao problema de classificação da Doença de Parkinson a partir de atributos vocais.

O benchmark foi conduzido utilizando exatamente o mesmo *pipeline* de pré-processamento e validação empregado nas etapas subsequentes deste trabalho, composto por: (i) tratamento de *outliers* via *Quantile Clipping*, (ii) normalização robusta (*RobustScaler*), (iii) balanceamento das classes por meio do algoritmo SMOTE e (iv) validação cruzada estratificada por sujeito (*GroupKFold*, com $K = 5$). Essa configuração assegura a inexistência de vazamento de dados (*data leakage*) entre sujeitos distintos e permite uma comparação justa entre os modelos avaliados.

Foram considerados modelos lineares e não lineares amplamente utilizados na literatura, implementados através da biblioteca *scikit-learn* [19], incluindo: Regressão Logística (L2), *K-Nearest Neighbors* (KNN), Árvores de Decisão, *Random Forest*, *Gradient Boosting*, AdaBoost, Redes Neurais Multicamadas (MLP), XGBoost e Máquinas de Vetores de Suporte (SVM), com diferentes configurações de *kernel*.

A Tabela II apresenta o ranking final dos modelos avaliados, considerando como métrica principal a Acurácia Balanceada média ($\overline{BA}$), acompanhada de seu desvio padrão (σ_{BA}). Métricas complementares, como AUC-ROC e F1-score, também foram analisadas para apoiar a decisão.

TABELA II
RANKING INICIAL DOS MODELOS AVALIADOS (*GroupKFold*, SEM *data leakage*)

Modelo	$\overline{BA}$	σ_{BA}
SVC (RBF)	0.7056	0.1080
Gradient Boosting	0.6949	0.1639
KNN	0.6703	0.1254
XGBoost	0.6688	0.1403
Árvore de Decisão	0.6510	0.1120
Random Forest	0.6436	0.1485
MLP	0.6371	0.1376
AdaBoost	0.6080	0.1511
Linear SVC (Calibrado)	0.5980	0.1819
Regressão Logística (L2)	0.5948	0.1854

Observa-se que o classificador SVC com *kernel* RBF apresentou o melhor desempenho médio em termos de Acurácia Balanceada ($\overline{BA} = 0,7056$), além de uma variabilidade moderada quando comparado aos demais modelos. Esse resultado indica um equilíbrio favorável entre desempenho preditivo e estabilidade estatística, sendo consistente com estudos prévios que destacam a eficácia das Máquinas de Vetores de Suporte em problemas com dados de alta complexidade e amostras limitadas.

Dessa forma, o modelo SVC com *kernel* RBF foi selecionado como modelo base para a etapa de otimização multiobjetivo de hiperparâmetros, a qual é detalhada na próxima seção.

D. Pipeline de Pré-processamento

O *pipeline* de pré-processamento foi construído de forma modular, garantindo reprodutibilidade e consistência ao longo das avaliações. As seguintes etapas foram aplicadas sequencialmente:

- 1) *Quantile Clipping*: remoção de *outliers* por meio do truncamento dos valores nos quantis 1% e 99%, reduzindo a influência de observações extremas;
- 2) *RobustScaler*: normalização baseada em mediana e intervalo interquartil, apropriada para dados com distribuição assimétrica;
- 3) SMOTE: balanceamento das classes por meio da geração de amostras sintéticas apenas no conjunto de treinamento de cada *fold*, preservando a integridade do conjunto de teste [15];
- 4) Classificador SVC-RBF: modelo final responsável pela classificação binária.

Para a implementação deste fluxo, utiliza-se a classe Pipeline da biblioteca `imblearn` [20]. Diferente das implementações convencionais presentes na biblioteca `scikit-learn` [19], o *ImbPipeline* é projetado para lidar corretamente com técnicas de reamostragem, garantindo que o algoritmo SMOTE seja aplicado exclusivamente aos dados de treinamento em cada *fold* da validação cruzada. No momento da inferência (teste), o *sampler* é automaticamente ignorado, preservando a distribuição original dos dados de validação e eliminando qualquer risco de *data leakage* durante o processo de avaliação das funções objetivo pelo MOPSO-CD.

Adicionalmente, o *pipeline* incorpora um mecanismo de ajuste dinâmico para o hiperparâmetro de vizinhos próximos ($k_neighbors$) do SMOTE. Devido à aplicação da validação cruzada por grupos (*GroupKFold*), a quantidade de amostras da classe minoritária pode variar significativamente entre diferentes *folds*. Para garantir a estabilidade do processo e evitar erros de execução, implementou-se uma lógica de segurança que redefine o valor de k para cada partição, respeitando a restrição $k \leq (n_{minority} - 1)$. Essa adaptação dinâmica assegura que o balanceamento sintético seja realizado de forma robusta, independentemente da distribuição específica de sujeitos em cada subconjunto de treinamento.

Visando garantir a reprodutibilidade dos experimentos e a consistência dos resultados apresentados, todas as etapas do processo que envolvem componentes estocásticos tiveram suas sementes de aleatoriedade fixadas (*seeds*). Essa configuração foi aplicada tanto na geração de amostras sintéticas pelo algoritmo SMOTE quanto na inicialização do classificador SVC, assegurando que as variações observadas no desempenho do modelo sejam decorrentes exclusivamente da exploração do espaço de busca pelo algoritmo de otimização e não de instabilidades numéricas inerentes aos processos aleatórios.

E. Estratégia de Validação

A avaliação do desempenho do classificador foi realizada por meio de validação cruzada estratificada com agrupamento por sujeito, utilizando o método *GroupKFold* com cinco partições. Essa estratégia assegura que todas as amostras de um mesmo indivíduo estejam contidas exclusivamente em um

único *fold*, eliminando correlações artificiais entre treino e teste, o que é crítico para a validade clínica de modelos de monitoramento personalizado [3], [21].

Formalmente, seja $\mathcal{D}$ o conjunto de dados e $\mathcal{S}$ o conjunto de sujeitos, a partição é definida de modo que:

$$\mathcal{D}_i \cap \mathcal{D}_j = \emptyset, \quad \forall i \neq j, \quad (6)$$

onde cada $\mathcal{D}_i$ contém apenas instâncias de sujeitos distintos.

F. Métricas de Avaliação

Dada a natureza desbalanceada do problema, a métrica principal adotada foi a Acurácia Balanceada (*Balanced Accuracy*), definida como:

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right), \quad (7)$$

onde TP , TN , FP e FN representam, respectivamente, verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

Para o cálculo desta métrica, definiu-se o ponto de referência $\mathbf{r} = (0.0, 1.0)$, posicionado ligeiramente além dos limites teóricos das funções objetivo minimizadas (f_1 e f_2). Esta escolha assegura que todas as soluções não dominadas encontradas ao longo das 300 gerações contribuam positivamente para o valor do hipervolume, permitindo monitorar de forma fidedigna o progresso da diversidade e da convergência do enxame em direção à Fronteira de Pareto.

Essa métrica fornece uma avaliação mais justa do desempenho do classificador em cenários de classes desbalanceadas, sendo amplamente recomendada na literatura [15].

Os valores de acurácia balanceada obtidos em cada *fold* são utilizados diretamente na definição das funções objetivo do problema de otimização, conforme apresentado na Seção II.

IV. ALGORITMO DE OTIMIZAÇÃO

Nesta seção é apresentado o algoritmo de otimização multi-objetivo empregado para a calibração dos hiperparâmetros do classificador SVC com *kernel* RBF. O problema foi resolvido por meio do algoritmo *Multi-Objective Particle Swarm Optimization with Crowding Distance* (MOPSO-CD), conforme implementado na biblioteca `pymoo` [13]. A dinâmica iterativa do enxame e sua integração com o processo de validação cruzada por sujeito são detalhadas no fluxograma da Fig. 2.

A. Fundamentação do Particle Swarm Optimization

O *Particle Swarm Optimization* (PSO) é um algoritmo de otimização inspirado no comportamento coletivo de enxames naturais, como bandos de aves e cardumes de peixes. Cada partícula representa uma solução candidata no espaço de decisão e evolui ao longo das iterações por meio da atualização de sua velocidade e posição [11].

Formalmente, a atualização da velocidade da partícula i na iteração k é dada por:

$$\mathbf{v}_i^{k+1} = \omega \mathbf{v}_i^k + c_1 r_1 (\mathbf{p}_i - \mathbf{x}_i^k) + c_2 r_2 (\mathbf{g}_i - \mathbf{x}_i^k), \quad (8)$$




Figura 2. Detalhamento do processo de otimização multiobjetivo.

onde:

- ω é o fator de inércia,
- c_1 e c_2 são os coeficientes cognitivo e social,
- $r_1, r_2 \sim \mathcal{U}(0, 1)$ são variáveis aleatórias,
- $\mathbf{p}_i$ é a melhor posição histórica da partícula,
- $\mathbf{g}_i$ é a melhor posição global ou local.

A posição da partícula é então atualizada por:

$$\mathbf{x}_i^{k+1} = \mathbf{x}_i^k + \mathbf{v}_i^{k+1}. \quad (9)$$

B. Extensão Multiobjetivo do PSO

No contexto multiobjetivo, não existe uma única solução ótima, mas sim um conjunto de soluções não dominadas que compõem a Fronteira de Pareto. Uma solução x^a domina outra solução x^b se:

$$f_m(x^a) \leq f_m(x^b), \forall m \in \{1, 2\}, \quad \text{e} \quad \exists m : f_m(x^a) < f_m(x^b). \quad (10)$$

O MOPSO adapta o PSO clássico para operar nesse cenário, mantendo um arquivo (*archive*) de soluções não dominadas que representa uma aproximação da Fronteira de Pareto [12].

C. Crowding Distance e Manutenção da Diversidade

Para evitar a concentração das soluções em regiões específicas da fronteira e promover diversidade, foi empregado o critério de *Crowding Distance* (CD). Esse mecanismo estima a densidade local de soluções ao redor de cada ponto da fronteira, priorizando soluções localizadas em regiões menos povoadas.

A distância de aglomeração de uma solução i é definida como:

$$CD_i = \sum_{m=1}^M \frac{f_m^{i+1} - f_m^{i-1}}{f_m^{\max} - f_m^{\min}}, \quad (11)$$

onde f_m^{i+1} e f_m^{i-1} são os valores das funções objetivo das soluções vizinhas na dimensão m .

No MOPSO-CD, a seleção das soluções líderes é orientada por esse critério, garantindo uma exploração equilibrada do espaço objetivo e evitando a convergência prematura em frentes restritas [16], [17].

D. Configuração do Algoritmo

Os parâmetros do MOPSO-CD utilizados neste estudo foram definidos com base em boas práticas da literatura e em experimentos preliminares. A Tabela III apresenta a configuração adotada.

TABELA III
PARÂMETROS DO ALGORITMO MOPSO-CD

Parâmetro	Valor
Tamanho da população	250
Número de gerações	300
Fator de inércia	0.6
Coefficiente social	2.0
Coefficiente cognitivo	2.0
Número de objetivos	2
Dimensão do espaço de decisão	3
Critério de diversidade	<i>Crowding Distance</i>
Métrica de convergência	Hipervolume
Ponto de referência	(0.0, 1.0)

E. Indicador de Convergência: Hipervolume

A qualidade da aproximação da Fronteira de Pareto foi avaliada por meio do indicador de Hipervolume (HV), uma métrica que mede o volume do espaço objetivo dominado pelo conjunto de soluções não dominadas em relação a um ponto de referência $\mathbf{r}$, apontando simultaneamente a proximidade e a diversidade das soluções obtidas [12], [22].

Formalmente, o hipervolume é definido como:

$$HV = \lambda \left(\bigcup_{x \in \mathcal{P}} [\mathbf{f}(x), \mathbf{r}] \right), \quad (12)$$

onde $\lambda(\cdot)$ representa a medida de Lebesgue e $\mathcal{P}$ representa o conjunto de soluções não dominadas.

O crescimento monotônico do hipervolume ao longo das gerações indica convergência e melhoria progressiva da fronteira aproximada.

F. Saída do Algoritmo

Ressalta-se que o MOPSO-CD não retorna uma única solução ótima, mas sim um conjunto de soluções não dominadas que compõem a Fronteira de Pareto. Cada solução representa um compromisso distinto entre desempenho médio e estabilidade do classificador.

A escolha de uma solução específica para implantação é realizada *a posteriori*, com base em critérios externos ao algoritmo de otimização, conforme detalhado na Seção III.

V. RESULTADOS E DISCUSSÃO

Nesta seção são apresentados e analisados os resultados obtidos a partir da aplicação do algoritmo MOPSO-CD para a otimização multiobjetivo dos hiperparâmetros do classificador SVC com *kernel* RBF. A análise é conduzida com base nos cinco experimentos independentes realizados, considerando a convergência do algoritmo, a diversidade da Fronteira de Pareto, o indicador de Hipervolume e a comparação com uma linha de base sem otimização.

A. Configuração Experimental

Foram conduzidos cinco experimentos independentes, cada um com sementes aleatórias distintas, mantendo-se constantes a população (250 partículas), o número de gerações (300) e o *pipeline* de avaliação descrito na Seção 3. Essa estratégia visa avaliar a robustez do processo de otimização frente à estocasticidade inerente ao PSO.

B. Convergência e Hipervolume

A convergência do algoritmo foi avaliada por meio da evolução do indicador de Hipervolume (HV) ao longo das gerações. A Figura 3 ilustra o comportamento observado nos experimentos. Observa-se um crescimento estritamente monotônico do hipervolume em todos os experimentos.

Notavelmente, há um salto acentuado de performance nas primeiras 50 gerações, período em que o MOPSO-CD identifica rapidamente as regiões de alta qualidade no espaço de busca. Esse comportamento evidencia a eficiência do MOPSO-CD em direcionar as partículas para a proximidade da Fronteira de Pareto global logo no início do processo evolutivo. Após essa fase de exploração intensiva, o algoritmo entra em um regime de refinamento (exploração local) estável, onde o ganho de hipervolume torna-se marginal e a fronteira atinge um patamar de convergência visualmente claro nas Figuras 3a a 3e. Tal resultado é consistente com as propriedades teóricas do indicador de hipervolume como métrica de qualidade e diversidade para algoritmos multiobjetivo [22], confirmando que o MOPSO-CD implementado foi capaz de explorar eficientemente o espaço de decisão e refinar progressivamente a aproximação da Fronteira de Pareto global.

C. Fronteira de Pareto e Diversidade

A Fronteira de Pareto final obtida em cada experimento é apresentada na Figura 4. Cada ponto representa uma solução não dominada, expressando um compromisso distinto entre desempenho médio (acurácia balanceada) e estabilidade (desvio padrão).

A Tabela IV apresenta a quantidade de soluções não dominadas identificadas ao final de cada experimento.

Observa-se que o algoritmo produziu consistentemente conjuntos de soluções não dominadas com diversidade adequada, evidenciando a eficácia do critério de *Crowding Distance* na manutenção de soluções bem distribuídas ao longo da fronteira. Com a produção de fronteiras de Pareto com cardinalidades variáveis pelo MOPSO-CD, observa-se o caráter

TABELA IV
NÚMERO DE SOLUÇÕES NÃO DOMINADAS POR EXPERIMENTO

Experimento	Soluções não dominadas
1	36
2	32
3	32
4	48
5	42

TABELA V
RESUMO DO PROCESSO DE CONSOLIDAÇÃO DAS SOLUÇÕES DE PARETO

Descrição	Quantidade
Total de soluções de Pareto (5 exp.)	$N_{total} = 190$
Soluções duplicadas	$N_{dup} = 110$
Soluções dominadas entre exp.	$N_{dom} = 63$
Total de soluções removidas	$N_{rem} = N_{dup} + N_{dom} = 173$
Soluções no Pareto consolidado final	$N_{global} = 17$

estocástico do algoritmo e a sensibilidade da paisagem multiobjetivo. Experimentos com maior diversidade de soluções não-dominadas indicam melhor exploração do espaço de decisão.

D. Fronteira de Pareto Consolidada Global

Após a execução dos cinco experimentos independentes do algoritmo MOPSO-CD, cada um resultando em uma fronteira de Pareto final, procedeu-se à consolidação global das soluções obtidas, com o objetivo de analisar o comportamento agregado do processo de otimização e eliminar redundâncias e soluções estritamente dominadas quando consideradas em conjunto.

1) *Processo de Consolidação das Soluções*: Inicialmente, todas as soluções não dominadas individuais provenientes dos arquivos de Pareto final de cada experimento foram reunidas em um único conjunto global. A partir desse conjunto agregado, foram aplicados dois procedimentos sucessivos de filtragem:


- 1) Remoção de soluções duplicadas: soluções com valores idênticos para as funções objetivo (f_1, f_2) foram identificadas e mantidas apenas uma vez, evitando redundância numérica na fronteira consolidada.
- 2) Eliminação de soluções dominadas globalmente: considerando o conjunto agregado completo, aplicou-se o critério de dominância de Pareto, removendo quaisquer soluções que fossem dominadas por pelo menos uma outra solução do conjunto, ainda que não fossem dominadas no experimento de origem.

Esse procedimento é essencial, pois soluções não dominadas em execuções isoladas podem tornar-se dominadas quando comparadas com soluções oriundas de outros experimentos, característica típica de algoritmos evolutivos estocásticos.


O conjunto final resultante, representa a fronteira de Pareto consolidada global, contendo exclusivamente soluções mutuamente não dominadas e únicas no espaço das funções objetivo.

2) *Análise Quantitativa da Consolidação*: A Tabela V apresenta um resumo quantitativo do processo de consolidação das soluções de Pareto.


Observa-se que uma fração significativa das soluções iniciais é removida durante o processo de consolidação, evidenciando tanto a sobreposição entre experimentos quanto




(a) Experimento 1




(b) Experimento 2



(c) Experimento 3



(d) Experimento 4



(e) Experimento 5

Figura 3. Evolução do Hipervolume (HV) ao longo das gerações — MOPSO-CD.

a presença de soluções dominadas apenas em uma análise global. Esse resultado reforça a importância de múltiplas execuções independentes em algoritmos evolutivos multiobjetivo.

3) *Visualização da Fronteira de Pareto Consolidada:* A Figura 5 apresenta a fronteira de Pareto consolidada global, construída a partir do conjunto consolidado de todos os experimentos realizados. Os pontos são representados com transparência (*alpha blending*), permitindo melhor visualização de regiões de maior densidade e sobreposição no espaço das funções objetivo.

A análise da curva permite uma interpretação clara do *trade-off* inerente ao problema: soluções localizadas no extremo esquerdo da fronteira priorizam a maximização da acurácia balanceada média, porém apresentam uma maior sensibilidade

às variações entre os *folds* da validação cruzada. Em contrapartida, à medida que se percorre a fronteira em direção à direita, observa-se o surgimento de modelos com maior estabilidade estatística (menor desvio padrão), ainda que à custa de uma redução marginal no desempenho preditivo médio. Essa dispersão de soluções confirma que a configuração ótima dos hiperparâmetros do SVC-RBF depende do equilíbrio desejado entre eficácia diagnóstica e robustez do modelo.

Nota-se que a fronteira consolidada preserva o formato característico de compromisso entre maximização da acurácia balanceada média e minimização de sua variabilidade, fornecendo um conjunto robusto de soluções candidatas para seleção posterior. Ressalta-se que, conforme a definição clássica de otimização multiobjetivo, o algoritmo MOPSO-CD tem como saída esse conjunto de soluções não dominadas, e




Figura 4. Fronteiras de Pareto finais por experimento (MOPSO-CD)

não uma única solução ótima, sendo qualquer escolha pontual realizada posteriormente um critério externo ao processo de otimização.

E. Consolidação Estatística dos Resultados e Critérios de Comparação

Esta subseção apresenta a consolidação quantitativa dos resultados obtidos ao longo dos experimentos conduzidos com o algoritmo MOPSO-CD, bem como os critérios adotados para comparação com a configuração de linha de base e para a escolha de uma solução de referência a partir da Fronteira de Pareto.

1) *Linha de Base (SVC-RBF Padrão)*: A linha de base corresponde ao desempenho do classificador SVC com *kernel* RBF configurado com hiperparâmetros padrão, sem qualquer processo de otimização. Os valores foram extraídos diretamente do ranking inicial de modelos avaliados sob validação cruzada estratificada por sujeito, utilizando a métrica $\overline{BA}$.

Os valores observados foram:

$$\overline{BA}_{\text{base}} = 0.7056 \quad (13)$$

$$\sigma_{\text{base}} = 0.1080 \quad (14)$$

Esses resultados evidenciam um desempenho moderado, associado a uma elevada variabilidade entre os *folds*, carac-




Figura 5. Fronteira de Pareto consolidada global após remoção de soluções duplicadas e dominadas entre experimentos.

terística comum em cenários com dados reais, desbalanceados e de alta variabilidade intersujeito.

2) *Melhor Solução Encontrada via MOPSO-CD*: A partir das Fronteiras de Pareto finais obtidas nos cinco experimentos independentes do MOPSO-CD, foi selecionada uma solução de referência com base em um critério *a posteriori*, cujo objetivo é exclusivamente analítico e comparativo.

Esta solução foi escolhida entre os pontos não dominados que apresentaram simultaneamente:

- A maior Acurácia Balanceada média;
- Um valor reduzido de desvio padrão da Acurácia Balanceada.

Os valores associados a essa solução foram:

$$\overline{BA}_{\text{best}} = 0.8405 \quad (15)$$

$$\sigma_{\text{best}} = 0.1069 \quad (16)$$

Ressalta-se que essa etapa de seleção não faz parte do algoritmo MOPSO-CD. O MOPSO-CD produz, como saída, um conjunto de soluções não dominadas que aproxima a Fronteira de Pareto do problema. A escolha de um ponto específico é realizada apenas para fins de interpretação, comparação com a linha de base e eventual aplicação prática.

3) *Média dos Experimentos com MOPSO-CD*: Devido à natureza estocástica dos algoritmos baseados em enxames de partículas, a análise do desempenho médio ao longo de múltiplas execuções independentes é considerada uma prática metodológica recomendada na literatura de otimização multiobjetivo.

Neste trabalho, foram conduzidos cinco experimentos independentes do MOPSO-CD, cada um resultando em uma Fronteira de Pareto final. Para cada experimento, foi extraída a melhor solução segundo o critério descrito anteriormente. As Acurácias Balanceadas médias obtidas foram:

- Experimento 1: $\overline{BA}_1 = 0.8244$
- Experimento 2: $\overline{BA}_2 = 0.8306$
- Experimento 3: $\overline{BA}_3 = 0.8229$
- Experimento 4: $\overline{BA}_4 = 0.8405$
- Experimento 5: $\overline{BA}_5 = 0.8405$

A Acurácia Balanceada média consolidada foi calculada como:

$$\overline{BA}_{\text{mean}} = \frac{1}{5} \sum_{i=1}^5 \overline{BA}_i \approx 0.8318 \quad (17)$$

Os desvios padrão correspondentes a cada experimento foram:

$$\sigma_i \in \{0.0758, 0.1103, 0.0443, 0.1069, 0.1069\} \quad (18)$$

A média dos desvios padrão foi então calculada como:

$$\sigma_{\text{mean}} = \frac{1}{5} \sum_{i=1}^5 \sigma_i \approx 0.0888 \quad (19)$$

Esse resultado indica que, além do ganho consistente em desempenho médio em relação à linha de base, o processo de otimização multiobjetivo contribuiu para a obtenção de modelos mais estáveis, reduzindo a variabilidade do desempenho entre diferentes partições dos dados.

F. Comparação com a Linha de Base

Como linha de base, foi considerado um modelo SVC-RBF configurado a partir de valores usuais da literatura ou obtidos por ranking univariado de atributos, sem otimização multiobjetivo dos hiperparâmetros.

A Tabela VI apresenta a comparação entre a linha de base, a melhor solução encontrada em cada experimento e a média das melhores soluções.

TABELA VI
COMPARAÇÃO ENTRE LINHA DE BASE E SOLUÇÕES OTIMIZADAS VIA MOPSO-CD

Configuração	BA	σ_{BA}
Linha de base (SVC-RBF padrão)	0.7056	0.1080
Melhor solução (MOPSO-CD)	0.8405	0.1069
Média dos experimentos (MOPSO-CD)	0.8318	0.0888

A comparação apresentada na Tabela VI evidencia ganhos expressivos obtidos pela otimização multiobjetivo via MOPSO-CD. Observa-se um aumento absoluto de aproximadamente 13.5 pontos percentuais na acurácia balanceada média em relação à linha de base, além de uma redução global da variabilidade do desempenho ao se considerar a média dos experimentos. Esses resultados confirmam a eficácia do processo de otimização multiobjetivo na busca por configurações mais precisas e estáveis do classificador SVC-RBF. Notavelmente, a melhor solução não apenas supera a acurácia da linha de base, mas o faz mantendo um desvio padrão similar ($\sigma_{\text{best}} = 0.1069$), o que sugere que o ganho em desempenho não foi obtido às custas da confiabilidade do modelo.

G. Critério de Escolha da Melhor Solução

É fundamental destacar que o MOPSO-CD não fornece uma única solução ótima, mas sim um conjunto de soluções não dominadas que compõem a Fronteira de Pareto. A seleção de uma solução específica para implantação não faz parte do algoritmo de otimização.

O desempenho detalhado das soluções pertencentes à Fronteira de Pareto para cada rodada experimental é sintetizado na

Tabela VII, apresentando tanto as métricas da melhor solução escolhida quanto os valores médios do conjunto de soluções não dominadas ($|\mathcal{P}|$).

TABELA VII
DESEMPENHO DAS SOLUÇÕES PARETO-ÓTIMAS POR EXPERIMENTO

Exp.	Melhor BA	Std (Melhor BA)	BA Média	Std Médio	$ \mathcal{P} $
1	0.8244	0.0758	0.6285	0.0186	36
2	0.8306	0.1103	0.7841	0.0635	32
3	0.8229	0.0443	0.6873	0.0258	32
4	0.8405	0.1069	0.7193	0.0447	48
5	0.8405	0.1069	0.6618	0.0254	42

Neste trabalho, adotou-se um critério *a posteriori* baseado em duas etapas:

- 1) Seleção das soluções cuja acurácia balanceada média satisfaz $\overline{BA} \geq \overline{BA}_{\max} - \varepsilon$;
- 2) Dentre essas soluções, escolha daquela com menor desvio padrão da acurácia balanceada.

Formalmente, seja $\mathcal{P}$ o conjunto de soluções não dominadas e $f_1(x)$, $f_2(x)$ as funções objetivo definidas na Seção 2. A solução escolhida x^* é dada por:

$$x^* = \arg \min_{x \in \mathcal{P}_\varepsilon} f_2(x), \quad (20)$$

$$\mathcal{P}_\varepsilon = \{x \in \mathcal{P} \mid f_1(x) \leq f_1^{\min} + \varepsilon\}.$$

Esse critério privilegia modelos com alto desempenho médio e maior estabilidade, característica desejável em aplicações clínicas.

H. Discussão Geral

Os resultados obtidos demonstram que a formulação multiobjetivo permite capturar explicitamente o *trade-off* entre desempenho e estabilidade, o que não é possível em abordagens mono-objetivo tradicionais. Além disso, a consistência observada entre os experimentos reforça a robustez do MOPSO-CD como estratégia de otimização de hiperparâmetros em cenários de dados biomédicos reais. Esses achados pavimentam o caminho para a aplicação dessa metodologia em sistemas de apoio à decisão clínica, onde a confiabilidade do diagnóstico é tão prioritária quanto sua sensibilidade.

VI. CONCLUSÃO

Este trabalho apresentou uma abordagem de otimização multiobjetivo para ajuste de hiperparâmetros de um classificador SVC com *kernel* RBF, aplicada à classificação da Doença de Parkinson a partir de atributos vocais. O problema foi formulado de modo a contemplar simultaneamente dois critérios fundamentais em cenários clínicos: desempenho médio de classificação, avaliado pela acurácia balanceada, e estabilidade do modelo, mensurada pelo desvio padrão dessa métrica ao longo dos *folds* de validação cruzada.

A modelagem matemática do problema, baseada em um espaço de decisão contínuo e em funções objetivo conflitantes, mostrou-se adequada para capturar o *trade-off* inerente entre acurácia e robustez. A utilização do algoritmo MOPSO-CD,

por meio da biblioteca *pymoo*, permitiu a obtenção de Fronteiras de Pareto bem distribuídas, com convergência consistente ao longo das gerações, conforme indicado pela evolução do hipervolume nos experimentos realizados.

Os resultados experimentais evidenciaram que a otimização multiobjetivo produziu soluções superiores à linha de base sem otimização, tanto em termos de melhoria da acurácia balanceada média, que foi incrementada em aproximadamente 13,5%, quanto na redução da variabilidade do desempenho. Essa melhoria substancial valida a hipótese de que a calibração precisa dos hiperparâmetros, guiada por múltiplos objetivos, é superior às configurações padrão do classificador em dados biomédicos complexos. Além disso, a análise conjunta de cinco execuções independentes demonstrou a robustez do processo de otimização frente à estocasticidade do algoritmo.

Ressalta-se que o MOPSO-CD não retorna uma solução única, mas um conjunto de soluções não dominadas que representam diferentes compromissos entre os objetivos. A escolha de uma solução específica para implantação foi realizada por meio de um critério externo *a posteriori*, baseado na maximização do desempenho médio sob uma tolerância controlada, seguida da minimização da instabilidade. Essa etapa, embora necessária do ponto de vista prático, não faz parte do algoritmo de otimização e reforça a natureza exploratória e informativa da abordagem multiobjetivo.

Como principais contribuições deste trabalho, destacam-se: (i) a formalização completa do problema de otimização multiobjetivo de hiperparâmetros no contexto de classificação da Doença de Parkinson; (ii) a integração de um *pipeline* de validação robusto, prevenindo vazamento de dados por meio do uso de *GroupKFold* e SMOTE; e (iii) a análise aprofundada da Fronteira de Pareto e do hipervolume como ferramentas de suporte à decisão.

Como trabalhos futuros, sugere-se a extensão da abordagem para outros modelos de aprendizado de máquina, como *ensembles* e redes neurais profundas, bem como a inclusão de métricas de utilidade clínica que quantifiquem o impacto de erros de diagnóstico no manejo do paciente. Ademais, a aplicação da metodologia a bases de dados multimodais e de maior escala pode fornecer evidências adicionais sobre a generalização e a aplicabilidade do método proposto em ambientes reais de apoio ao diagnóstico.

REFERÊNCIAS

- [1] World Health Organization, "Parkinson's disease: A public health approach," *WHO*, 2023. [Online]. Available: <https://www.who.int>
- [2] M. A. Little, P. E. McSharry, S. J. Roberts, D. A. E. Costello, and I. M. Moroz, "Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection," *Biomedical Engineering Online*, vol. 6, no. 23, 2007.
- [3] M. A. Little, P. E. McSharry, E. J. Hunter, J. Spielman, and L. O. Ramig, "Suitability of dysphonia measurements for telemonitoring of parkinson's disease," *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 4, pp. 1015–1022, 2009.
- [4] X. Shen *et al.*, "Voice-based biomarkers for parkinson's disease detection," *IEEE Journal of Biomedical and Health Informatics*, 2021.
- [5] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995.
- [6] N. E. Saeedi, F. Almasganj, and F. Torabinejad, "Support vector wavelet adaptation for pathological voice assessment," *Comput. Biol. Med.*, vol. 41, no. 9, pp. 822–828, Sep. 2011.

- [7] S. Chen and F. DuBois Bowman, "A novel support vector classifier for longitudinal high-dimensional data and its application to neuroimaging data," *Statistical Analysis and Data Mining: The ASA Data Science Journal*, vol. 4, no. 6, p. 604–611, Nov. 2011. [Online]. Available: <http://dx.doi.org/10.1002/sam.10141>
- [8] N. Erfanian Saeedi, F. Almasganj, and F. Torabinejad, "Support vector wavelet adaptation for pathological voice assessment," *Computers in Biology and Medicine*, vol. 41, no. 9, p. 822–828, Sep. 2011. [Online]. Available: <http://dx.doi.org/10.1016/j.compbiomed.2011.06.019>
- [9] F. Karl, T. Pielok, J. Moosbauer, F. Pfisterer, S. Coors, M. Binder, L. Schneider, J. Thomas, J. Richter, M. Lang, E. C. Garrido-Merchán, J. Branke, and B. Bischl, "Multi-objective hyperparameter optimization in machine learning—an overview," *ACM Transactions on Evolutionary Learning and Optimization*, vol. 3, no. 4, p. 1–50, Dec. 2023. [Online]. Available: <http://dx.doi.org/10.1145/3610536>
- [10] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *Journal of Machine Learning Research*, vol. 13, pp. 281–305, 2012.
- [11] J. Kennedy and R. Eberhart, "Particle swarm optimization," in *Proceedings of the IEEE International Conference on Neural Networks*. IEEE, 1995, pp. 1942–1948.
- [12] C. A. Coello Coello, "A comprehensive survey of evolutionary-based multiobjective optimization techniques," *Knowledge and Information Systems*, 2004.
- [13] J. Blank and K. Deb, "Pymoo: Multi-objective optimization in python," *IEEE Access*, vol. 8, pp. 89 497–89 509, 2020.
- [14] N. V. Chawla, K. W. Bowyer, L. O. Hall, and P. P. W. Kegelmeyer, "Smote: synthetic minority over-sampling technique," *Journal of artificial intelligence research*, vol. 16, pp. 321–357, 2002.
- [15] S. Boughorbel, F. Jarray, and M. El-Anbari, "Optimal classifier for imbalanced data using matthews correlation coefficient," *IEEE Transactions on Knowledge and Data Engineering*, vol. 29, no. 3, pp. 655–669, 2017.
- [16] C. R. Raquel and P. C. Naval Jr, "An effective multi-objective particle swarm optimization algorithm," in *Proceedings of the 7th annual conference on Genetic and evolutionary computation*, 2005, pp. 151–158.
- [17] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm: Nsga-ii," *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182–197, 2002.
- [18] Y. Zhang *et al.*, "Machine learning approaches for parkinson's disease classification," *Scientific Reports*, vol. 13, 2023.
- [19] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [20] G. Lemaitre, F. Nogueira, and K. A. Christos, "Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning," *Journal of Machine Learning Research*, vol. 18, no. 1, pp. 559–563, 2017.
- [21] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need for differentiation of within-subject and between-subject variation in personalized health monitoring," *Journal of Biomedical Informatics*, vol. 70, pp. 44–52, 2017.
- [22] E. Zitzler and L. Thiele, "Multiobjective evolutionary algorithms: a comparative case study and the strength pareto approach," *IEEE Transactions on Evolutionary Computation*, vol. 3, no. 4, pp. 257–271, 1999.



Alfa Marine Ferreira cursando mestrado no Programa de Pós-Graduação de Engenharia Elétrica (PPGEE) da UFPA na área de Computação Aplicada, linha de pesquisa de Inteligência Computacional. Bacharel em Engenharia Elétrica pela Universidade Federal do Pará (UFPA, 2025). Atuou como estagiária na Siemens Energy por dois anos, no setor de Engenharia Operacional na subsidiária Guascor do Brasil, unidade de Belém-PA. Atuou como estagiária na Vale S.A. por seis meses, no setor de Engenharia de Processos na Mina de Onça Puma, em Ourilândia do Norte-PA. Atuou como bolsista de iniciação científica na UFPA por 3 anos, com pesquisas relacionadas às áreas de programação, sistemas de controle e inteligência computacional. Atualmente faz parte do Laboratório de Inteligência Artificial aplicada a Smart Cities (LABCITY).



Anderson Viana cursando mestrado no Programa de Pós-Graduação de Engenharia Elétrica (PPGEE) da UFPA na área de Computação Aplicada, linha de pesquisa de Inteligência Computacional. Bacharel em Sistemas de Informação pela Universidade Federal do Pará (UFPA) e pós-graduado em MBA em Gestão de Pessoas. Experiência profissional nas áreas de Tecnologia da Informação e Comunicação (TIC), com atuação em análise, desenvolvimento, suporte e manutenção de sistemas, gerenciamento de redes e infraestrutura computacional. Atualmente,

sou Analista de Tecnologia da Informação da Universidade Federal Rural da Amazônia (UFRA) e participante dos grupos de pesquisa do Laboratório de Simulação de Biologia Computacional (SIMBIC) e do Laboratório de Neurofisiologia Eduardo Osvaldo Cruz (LNEOC), ambos da Universidade Federal do Pará (UFPA).